

Amazon Ürün Yorumlarında Üç Sınıflı Duygu Analizi: Klasik, Derin ve Transformer Tabanlı Modellerin Karşılaştırmalı Değerlendirmesi

Furkan Öztürk
Kocaeli Üniversitesi
Yazılım Mühendisliği
230229083@kocaeli.edu.tr

Özet—Bu çalışmada, Amazon Fine Food Reviews veri seti üzerinde İngilizce ürün yorumlarının Negatif, Nötr ve Pozitif olarak sınıflandırıldığı uçtan uca bir metin madenciliği sistemi geliştirilmiştir. Yıldız puanları üç sınıfa eşlenmiş, sınıf dengesizliği alt örnekleme ile giderilerek 89.267 örnekten oluşan dengeli bir küme elde edilmiştir. Metinler TF-IDF (birli, ikili ve üçlü n-gram) ve on dört istatistiksel öznitelikle temsil edilmiş; Lojistik Regresyon, Doğrusal SVM ve LightGBM ile birlikte LSTM ve BiLSTM dizi modelleri ve ince ayarlı (fine-tuned) DistilBERT dönüştürücü modeli eğitilmiştir. Temel sistemin üzerine dört geliştirme önerilmiştir: (i) yorum başlığının (summary) özniteliklere katılması, (ii) klasik modellerin olasılıklarını öğrenilen bir meta modelle birleştiren istifleme (stacking) topluluğu, (iii) tahminleri kelime düzeyinde renklendiren canlı LIME açıklaması ve (iv) önceden eğitilmiş bir Transformer'ın (DistilBERT) göreve ince ayarlanması. Tüm model seçimi/eşik ayarı yalnızca doğrulama kümesinde yapılmış, test kümesine yalnızca en sonda bir kez bakılmıştır. Kontrollü ablation deneyleri başlık bütünleştirmenin F1-makro skorunu model başına yaklaşık +0,03 artırdığını; sızıntısı giderilmiş istifleme topluluğunun klasik modeller arasında 0,7577 F1-makro ile en iyi olduğunu; ince ayarlı DistilBERT'in ise 0,8113 F1-makro ile tüm modelleri açık farkla geçtiğini (test $\approx$ doğrulama) göstermiştir. Önceki temel modele göre toplam kazanç +6 F1 puanıdır. Ayrıca öznitelik çıkarımındaki bir veri sızıntısı, vektörleştiricinin yalnızca eğitim kümesinde uyarlanmasıyla giderilmiştir. Tüm bileşenler etkileşimli bir web arayüzünde sunulmuştur.

Anahtar Kelimeler—duygu analizi, metin madenciliği, TF-IDF, topluluk öğrenmesi, istifleme (stacking), LightGBM, LSTM, Transformer, BERT, DistilBERT, ince ayar (fine-tuning), açıklanabilir yapay zeka, LIME, veri sızıntısı.

I. GİRİŞ

Çevrimiçi ürün yorumları, tüketici kararlarını ve üretici geri bildirim süreçlerini doğrudan etkileyen büyük ölçekli ve yapısız bir metin kaynağıdır. Bir ürünün binlerce yorumunu insan eliyle değerlendirmek pratik olmadığından, bu yorumların duygu kutuplarına otomatik olarak ayrılması metin madenciliğinin en yaygın ve değerli uygulamalarından biri haline gelmiştir. Otomatik duygu analizi; itibar takibi, ürün iyileştirme, öneri sistemleri ve pazar analizi gibi birçok alanda doğrudan karşılık bulur.

Bu çalışma, Amazon gıda ürünü yorumlarını üç sınıfa (Negatif, Nötr, Pozitif) ayıran tam bir işlem hattı sunar: veri hazırlama, keşifsel veri analizi (EDA), metin ön işleme, öznitelik çıkarımı, model eğitimi, değerlendirme ve sunum. Sıkça tercih

edilen ikili (olumlu/olumsuz) kurgunun aksine, nötr sınıfının eklenmesi problemi belirgin biçimde zorlaştırır: nötr yorumlar hem olumlu hem olumsuz ifadeler barındırabildiğinden karar sınırı bulanıklaşır ve sınıflar arası karışma artar. Bu nedenle çalışmada hem klasik makine öğrenmesi hem de dizi tabanlı derin öğrenme modelleri eğitilip karşılaştırılmış, ardından sistemin hem doğruluğunu hem de yorumlanabilirliğini artıran üç somut geliştirme tasarlanıp deneysel olarak doğrulanmıştır.

Bu raporun odaklandığı katkılar şunlardır:

- 1) Yorum başlığının (summary) gövde metniyle birleştirilerek öznitelik uzayına katılması ve etkisinin kontrollü ablation ile nicel ölçümü;
- 2) Klasik modellerin olasılık çıktılarını birleştiren topluluk yöntemleri (ağırlıklı oylama ve, sızıntısız olarak doğrulama olasılıkları üzerinde eğitilen, öğrenilen bir meta modelle istifleme/stacking) ve bunların tekil modellerle karşılaştırılması;
- 3) Önceden eğitilmiş bir Transformer modelinin (DistilBERT) göreve ince ayarlanarak ayrı bir model olarak eklenmesi ve en yüksek başarıyı sağlaması;
- 4) Her tahmini, girdideki kelimelerin katkısına göre renklendiren canlı LIME açıklaması;
- 5) Öznitelik çıkarımındaki bir veri sızıntısının giderilmesi (vektörleştirici ve ölçekleyicinin yalnızca eğitim kümesinde uyarlanması) ve tüm model/eşik seçimlerinin yalnızca doğrulama kümesinde yapılması;
- 6) Yorum düzeyi sınıflandırmanın ötesinde, ürün varlıklarına (aspect) göre cümle düzeyinde duygu kırılımı çıkararak eyleme dönük geri bildirimin görselleştirilmesi.

II. İLGİLİ ÇALIŞMALAR

Duygu analizi literatürü, sözlük (lexicon) tabanlı yaklaşımlardan denetimli makine öğrenmesine ve son yıllarda derin öğrenme ile dönüştürücü (Transformer) modellerine doğru evrilmiştir. Pang ve Lee [2], görüş madenciliğinin temel problemlerini ve denetimli yaklaşımların üstünlüğünü ortaya koymuştur. Metin sınıflandırmada TF-IDF gibi torba kelime (bag-of-words) temsilleri, özellikle doğrusal modellerle birlikte güçlü ve yorumlanabilir bir taban oluşturur; Joachims [7] destek vektör makinelerinin metin kategorizasyonundaki etkinliğini göstermiştir. Gradyan artırma yöntemleri, özellikle

LightGBM [4], seyrek yüksek boyutlu öznitelikler üzerinde verimli ve rekabetçi sonuçlar verir. Dizi modelleri arasında LSTM [5] kelime sırasını modelleyerek bağlamsal ipuçlarını yakalayabilir; ancak yeterli veri ve hesaplama olmadığında klasik yöntemleri her zaman geçemez. Model kararlarının açıklanması için LIME [6], herhangi bir sınıflandırıcının tahminlerini yerel olarak yorumlamaya imkan tanıyan model bağımsız bir çerçevedir. Bu çalışma, Amazon Fine Food Reviews [1] veri seti üzerinde bu yaklaşımları üç sınıflı bir kurguda birleştirip karşılaştırmakta ve üzerine başlık bütünleştirme ile topluluk öğrenmesi gibi pratik geliştirmeler eklemektedir.

III. VERİ SETİ VE KEŞİFSEL ANALİZ

A. Veri ve Etiketleme

Amazon Fine Food Reviews veri seti yaklaşık 568 bin yorum içerir ve her yorumun 1 ile 5 arası bir yıldız puanı vardır. Her kayıta, kısa bir başlık (summary) ve daha uzun bir gövde metni (text) bulunur. Yıldız puanları şu kural ile üç sınıfa eşlenmiştir: 1 ve 2 puan Negatif (sınıf 0), 3 puan Nötr (sınıf 1) ve 4 ve 5 puan Pozitif (sınıf 2).

B. Sınıf Dengesizliği ve Dengeleme


Ham veri yıldız dağılımı bakımından güçlü biçimde pozitif eğilimlidir; 4 ve 5 yıldız yorumlar ezici çoğunluğu oluşturur. Bu dengesizlik, modelin çoğunluk sınıfına yanlı (majority-bias) öğrenmesine ve azınlık sınıflarda düşük duyarlılığa yol açar. Sorunu gidermek için en küçük sınıf baz alınarak alt örnekleme (undersampling) uygulanmış ve her sınıftan 29.756 örnek seçilerek toplam 89.267 örnekten oluşan tam dengeli bir küme elde edilmiştir (Tablo I). Dengeli kurguda rastgele tahmin başarısı %33,3 düzeyindedir; bu da raporlanan skorların anlamlı bir taban üzerine kurulduğunu gösterir.

C. Keşifsel Bulgular


Keşifsel analizde gözlemlenen başlıca eğilimler: (i) yorum uzunluğu ile duygu arasında zayıf bir ilişki vardır, çok kısa yorumlar daha belirsizdir; (ii) başlık alanı, gövdeye kıyasla çok daha kısa olmasına rağmen orantısız biçimde duygu yoğun sözcükler taşır (ör. “awful”, “perfect”, “waste”); (iii) sözcük frekansları Zipf yasasına uyar, dolayısıyla TF-IDF’te seyrek ama ayırt edici terimlerin ağırlıklandırılması önemlidir. Bu bulgular, hem başlık bütünleştirme hem de n-gram TF-IDF tercihini doğrudan motive etmiştir. Aşağıda bu eğilimleri niceleyen başlıca keşifsel grafikler sunulmaktadır.

Şekil 1, dengeleme sonrası üç sınıfın eşit ($\approx 33,3$) temsil edildiğini görsel olarak doğrular; böylece raporlanan makro ortalamalar herhangi bir sınıf lehine yanlılık taşımaz.

Yorum uzunluğunun sınıf bazlı yoğunluğu (Şekil 2) üç sınıfta da sağa çarpık (right-skewed) bir dağılım izler: yorumların büyük çoğunluğu 500 karakterin altındadır ve dağılımın kuyruğu 2.500 karaktere kadar incilir. Nötr sınıf kuyrukta diğer ikisinden bir miktar daha kalın bir kütle taşır; bu, kararsız kullanıcıların görüşlerini gerekçelendirmek için daha uzun metinler yazma eğilimiyle tutarlıdır.



Şekil 1. Dengeleme sonrası sınıf dağılımı: her sınıftan ≈ 29.756 örnek.




Şekil 2. Karakter uzunluğunun sınıf bazlı dağılımı; her sınıf sağa çarpıktır, nötr sınıfın kuyruğu hafifçe daha kalındır.


Başlık ile gövde uzunluklarının karşılaştırması (Şekil 3) başlık bütünleştirme tercihinin ardındaki temel gözlemi nicelleştirir: ortalama gövde uzunluğu sınıfa göre 415 ile 510 karakter arasında değişirken, başlık alanı yalnızca ≈ 25 karakterdir, yani başlık, toplam metnin %5’inden azıdır. Bu denli kısa bir alanın model başarımına ölçülebilir katkı sağlaması (Bölüm VIII), içerdiği sinyalin uzunluğuyla değil yoğunluğuyla ilgili olduğunu gösterir.

Sayısal özniteliklerin korelasyon matrisi (Şekil 4) iki metodolojik bulgu sunar. Birincisi, etiket (label) ile yıldız puanı (Score) arasındaki 0,97’lik beklenen yüksek korelasyon, eşleme kuralının tutarlılığını doğrulayan bir akıl sağlığı kontrolüdür. İkincisi ve daha önemlisi, yorum uzunluğu, kelime sayısı ve faydalılık gibi yüzeysel sayısal özniteliklerin etiketle korelasyonu pratikte ihmal edilebilirdir ($|r| \leq 0,10$). Bu, duygu sınıfının yalnızca metin istatistiği öznitelikleriyle kestirilemeyeceğini, asıl ayırt edici gücün TF-IDF içeriğinde olduğunu ortaya koyar ve iki temsilin birleştirilmesi kararını destekler.

Sınıfa özgü ayırt edici kelimeler (Şekil 5), her sınıfı sınıf içi ve sınıf dışı frekans oranı farkıyla en güçlü ayıran terim-




Şekil 3. Sınıf başına ortalama gövde (mavi) ve başlık/summary (turuncu) uzunluğu; başlık, gövdenin yaklaşık yirmide biri kadardır.



Şekil 4. Sayısal öznitelikler arası korelasyon. Etiket ile Score 0,97 (tutarlılık kontrolü); yüzeyel öznitelikler etiketle neredeyse ilişkisizdir ($|r| \leq 0,10$).

leri listeler. Negatif sınıfta “money”, “disappointed”, “bad”, “waste”; pozitif sınıfta “love”, “best”, “delicious”, “perfect” baskındır. Nötr sınıfın ayırt edici kelimeleri (“taste”, “flavor”, “bit”, “little”, “ok”, “probably”) ise belirgin bir kutup taşımaz; bu sözcüksel belirsizlik, nötr sınıfın neden tüm modellerde en zor sınıf olduğunun doğrudan habercisidir. Negatif sınıfın kelime bulutu (Şekil 6) aynı örüntüyü görsel olarak özetler.




Şekil 5. Sınıf ayırt edici 15 kelime. Negatif ve pozitif sınıflar net kutuplu; nötr sınıfın terimleri kutupsuzdur.




Şekil 6. Negatif sınıf kelime bulutu: “money”, “waste”, “disappointed”, “awful” öne çıkar.

Sözcük frekanslarının log-log ölçekteki sıralama ve frekans grafiği (Şekil 7) gözlenen dağılımın ideal Zipf ($1/n$) doğrusuyla geniş bir aralıkta örtüştüğünü gösterir. Az sayıda yüksek frekanslı sözcük toplam kütenin büyük kısmını oluştururken ayırt edici terimler uzun kuyrukta yer alır; bu, TF-IDF’in sublinear_tf ağırlıklandırması ile min_df/max_df budamasının neden gerekli olduğunu doğrular.



Şekil 7. Sözcük sıralama ve frekans dağılımı (log-log). Gözlenen eğri ideal Zipf ($1/n$) doğrusunu yakından izler.

Son olarak, yorumların faydalılık oylarına göre gruplanması (Şekil 8) ikincil ama ilgi çekici bir örüntü ortaya koyar: oylarının tamamı “faydalı” bulunan yorumların ortalama duygu sınıfı (1,21) belirgin biçimde pozitive kayar; hiç oy almamış veya oylarının yarısından azı faydalı bulunan yorumlar ise nötr ile negatif arası bölgede ($\approx 0,32$) yoğunlaşır. Topluluk onayı pozitif yorumlarla ilişkili görünmekle birlikte, korelasyonun zayıflığı (Şekil 4) bu özneliliğin tek başına güçlü bir kestirici olmadığını gösterir.



Şekil 8. Faydalılık oy yüzdesine göre ortalama duygu sınıfı; %100 faydalı yorumlar belirgin biçimde daha pozitifdir.

Tablo I
VERİ KÜMESİ BÖLÜMLERİ

Küme	Örnek	Oran	Dağılım
Eğitim	62.486	%70	dengeli ($\approx$ %33,3)
Doğrulama	13.390	%15	dengeli ($\approx$ %33,3)
Test	13.391	%15	dengeli ($\approx$ %33,3)
Toplam	89.267	%100	29.756 / 29.756 / 29.755

IV. ÖN İŞLEME VE ÖZNETELİK ÇIKARIMI

A. Metin Temizleme


Her yorum şu adımlardan geçirilmiştir: küçük harfe çevirme; HTML etiketleri ve URL'lerin kaldırılması; ASCII dışı karakterlerin, noktalama ve rakamların temizlenmesi; sözcüklere ayırma (tokenization); WordNet ile lemmatization; ve İngilizce durak kelimelerin elenmesi. Kritik bir ayrıntı olarak, olumsuzlama kelimeleri (not, no, never, don, didn...) durak kelime listesinden çıkarılarak korunmuştur. Aksi halde "not good" gibi ifadeler temizlikte "good"a indirgenir ve olumsuzluk kaybolurdu; korunmaları sayesinde TF-IDF bigramları ("not good", "didn like") olumsuzluğu yakalayabilmiştir.

B. Öznitelikler

İki tür öznitelik birleştirilmiştir. (i) TF-IDF vektörleri: `max_features=50000`, `ngram=(1, 3)`, `sublinear_tf=True`, `min_df=3`, `max_df=0.90`. Bigram ve trigramların eklenmesi, olumsuzlama ve sık çoklu kalıpların yakalanmasını sağlar. (ii) Yorum başına on dört istatistiksel öznitelik: karakter uzunluğu, kelime sayısı, ünlem ve soru işareti sayısı, ortalama kelime uzunluğu, büyük harf oranı, TextBlob tabanlı duygu polaritesi ve özneliliği ile birlikte olumsuzlama sözcüğü sayısı, tümü büyük harf oranı, cümle sayısı, ortalama cümle uzunluğu, benzersiz kelime oranı ve noktalama yoğunluğu. Sayısal öznitelikler `StandardScaler` ile ölçeklenip TF-IDF matrisiyle birleştirilmiştir. Derin dizi modelleri için metinler ayrıca tamsayı dizilerine kodlanmıştır (maks. uzunluk 200,

sözlük 50.000). DistilBERT ise TF-IDF kullanmaz; kendi alt kelime (WordPiece) tokenizer'ı ile ham metni (başlık + gövde) doğrudan işler.

Sayısal özniteliklerin taşıdığı sinyali doğrulamak için, en bilgilendirici olanlardan biri olan TextBlob polaritesinin sınıf bazlı dağılımı keman (violin) grafiğiyle incelenmiştir (Şekil 9). Polaritenin medyanı Negatif'ten Pozitif'e doğru tutarlı biçimde artar ancak üç dağılım da geniş ölçüde örtüşür ve nötr sınıf sıfır çevresinde neredeyse simetrik bir kütle taşır. Bu, polaritenin yararlı ama tek başına yetersiz bir öznitelik olduğunu, asıl değerini TF-IDF ile birleştirdiğinde kazandığını (Bölüm VIII), görsel olarak doğrular.



Şekil 9. TextBlob polaritesinin sınıf bazlı dağılımı (keman grafiği). Medyan Negatif→Pozitif artar; dağılımlar büyük ölçüde örtüşür.

C. Veri Sızıntısının Giderilmesi

Metodolojik bir düzeltme olarak, TF-IDF vektörleştirici ve ölçekleyici bu çalışmada yalnızca eğitim kümesinde uyarlanmıştır (`fit`). Önceki sürümde bu bileşenler tüm veri üzerinde uyarlanıyordu; bu, test bilgisinin öznitelik üretimine sızması (data leakage) anlamına gelir ve iyimser yanlı skorlara yol açabilir. Düzeltme sonrasında skorların bozulmaması (hatta hafif artması), elde edilen başarımın modelin gerçek genelleme kabiliyetini yansıttığını doğrular.

D. Veri Bölümleme

Veri, sınıf oranları korunarak (stratified) %70/%15/%15 olacak biçimde eğitim, doğrulama ve test kümelerine ayrılmıştır (`random_state=42`). Tüm modeller aynı bölümleme üzerinde eğitilip değerlendirildiğinden karşılaştırmalar adildir.

V. MODELLER

A. Klasik Modeller

Klasik modeller, TF-IDF ile sayısal özniteliklerin birleştirildiği seyrek matris üzerinde çalışır:

- Lojistik Regresyon (`C=1`, `lbfgs`, `class_weight=balanced`): hızlı, yorumlanabilir ve güçlü bir doğrusal taban. Katsayıları aynı zamanda açıklama (LIME) için kullanılır.
- Doğrusal SVM (`LinearSVC`, `C=0.5`, `dual=False`): yüksek boyutlu seyrek metin

verisinde etkilidir. Olasılık üretebilmesi için CalibratedClassifierCV (3 kat) ile kalibre edilmiştir; bu, topluluk için zorunludur.

- LightGBM (127 yaprak, lr=0.05, doğrulamada erken durdurma): doğrusal olmayan etkileşimleri yakalayan gradyan artırma yöntemi.
- ComplementNB (alpha doğrulamada ayarlı): dengeli/seyrekleştirilmiş metinde etkili bir Naive Bayes çeşididir; yalnızca TF-IDF üzerinde çalışır.

Tüm hiperparametreler (C, yaprak sayısı, alpha vb.) yalnızca doğrulama kümesinde aranmış, test kümesine yalnızca en sonda bakılmıştır.

B. Derin Modeller

Derin modeller kelime dizileri üzerinde çalışır ve şu katmanlardan oluşur: Gömme (Embedding, 64 boyut, mask_zero); ardından SpatialDropout(0,3); LSTM(64) veya çift yönlü BiLSTM; Dense(32, ReLU); Dropout(0,4); ve son olarak Softmax(3). Eğitim, Adam ($\eta = 5 \times 10^{-4}$, clipnorm=1), erken durdurma ve öğrenme oranı azaltma ile yapılmıştır. Hesaplama bütçesi nedeniyle derin modeller eğitim kümesinin bir alt kümesi (45.000 örnek) ile eğitilmiştir.

C. Transformer Tabanlı Model (DistilBERT)

Klasik ve dizi tabanlı modellere ek olarak, önceden büyük metin yığınları üzerinde eğitilmiş bir Transformer olan DistilBERT [8] göreve ince ayarlanmıştır (fine-tuning). LSTM/BiLSTM modellerinin gömüleri sıfırdan öğrenmesinin aksine, DistilBERT dile dair bilgiyi ön eğitiminden taşır; bu aktarım öğrenmesi, sınırlı görev verisiyle bile güçlü temsiller sağlar. Model, ham metin (başlık + gövde) üzerinde kendi WordPiece tokenizer'ı (maks. uzunluk 192) ile çalışır. Sınıflandırma başlığı üç sınıf için eklenmiş; tüm ağırlıklar AdamW ($\eta = 2 \times 10^{-5}$, ağırlık sönümü 0,01, doğrusal ısınma) ile 2 dönem (epoch) boyunca güncellenmiştir. Her dönem sonunda doğrulama makro-F1'i ölçülmüş ve en iyi dönem (early-stopping mantığı) saklanmıştır. Eğitim yalnızca CPU üzerinde yapıldığından dengeli 62.486 örneklik eğitim kümesi kullanılmış, dönem başına ≈ 4 saat sürmüştür. DistilBERT, çıkarımda da seçilebilir ayrı bir model olarak web arayüzüne entegre edilmiştir.

VI. ÖNERİLEN GELİŞTİRMELER

A. Başlık (Summary) Bütünleştirme

Amazon yorumları, gövde metninin yanında kısa bir başlık alanı da içerir (ör. "Awful, do not buy", "Best coffee ever"). Bu başlıklar çoğunlukla duygu açısından çok yoğundur. Geliştirilmede başlık, gövdeyle aynı temizleme hattından geçirilip onun önüne eklenir ve TF-IDF bu birleşik metin üzerinde yeniden uyarlanır; başka bir deyişle birleşik metin, temizlenmiş başlık ile temizlenmiş gövdenin ardışık olarak birleştirilmesinden oluşur. Çıkarım anında da aynı işlem uygulanır; arayüz, başlık için isteğe bağlı ayrı bir giriş alanı sunar (Şekil 21). Etkisi kontrollü ablation ile ölçülmüştür (Bölüm VIII.B).

B. Topluluk Öğrenmesi: Oylama ve İstifleme (Stacking)

Üç klasik model (LR, SVM, LightGBM) farklı tümevarımsal önyargılara (doğrusal, marj temelli, ağaç temelli) sahip olduğundan farklı hata desenleri üretir; çıktılarının birleştirilmesi bu hataları kısmen telafi ederek varyansı düşürür. İki birleştirme yöntemi kullanılmıştır. (i) Ağırlıklı oylama: modellerin sınıf olasılıkları, doğrulama F1'lerine göre ağırlıklandırılıp toplanır ($\hat{y} = \arg \max_y \sum_m w_m P_m(y | x)$). (ii) İstifleme (stacking): sabit bir kural yerine, birleştirmeyi öğrenen bir meta model (Lojistik Regresyon) kullanılır; meta model, taban modellerin olasılıklarını girdi alır. Sızıntıyı önlemek için meta model, taban modellerin eğitim olasılıklarıyla değil, doğrulama kümesi olasılıklarıyla eğitilir; böylece taban modellerin eğitim setini ezberlemesinden kaynaklanan iyimser yanlılık engellenir. İstifleme, ağırlıklı oylamayı geçerek klasik modeller arasında en iyi sonucu vermiştir (0,7577 vs 0,7527).

C. Canlı LIME Açıklaması

Tahminlerin yorumlanabilirliği için, girdideki her kelimenin tahmin edilen sınıfa katkısı

$$c_w = \text{tfidf}(w) \times \beta_{\hat{y},w}$$

olarak hesaplanır; burada $\beta_{\hat{y},w}$, Lojistik Regresyonun ilgili sınıf için kelime katsayısıdır. Pozitif c_w tahmini destekler (yeşil), negatif c_w karşı çıkar (kırmızı); renk yoğunluğu $|c_w|$ ile orantılıdır. Sözlükte bulunmayan kelimeler ayrıca işaretlenir. Bu, LIME [6] fikrinin hafif ve gerçek zamanlı bir uyarlamasıdır (Şekil 22 ve 23).

VII. DENEYSEL KURULUM VE DEĞERLENDİRME

Tüm modeller aynı test kümesinde (13.391 örnek) değerlendirilmiştir. Sınıflar dengeli olduğundan birincil ölçüt olarak F1-makro (sınıflar arası ortalama F1) seçilmiş; ayrıca doğruluk, makro kesinlik ve duyarlılık raporlanmıştır. Makro ortalama, her sınıfa eşit ağırlık verdiği için azınlık sınıflardaki başarıyı da yansıtır. Geliştirme öncesi/sonrası karşılaştırmalar, yalnızca öznitelik metni değiştirilerek aynı işlem hattının iki kez çalıştırıldığı kontrollü ablation ile yapılmıştır; böylece gözlenen fark yalnızca incelenen değişkene atfedilebilir.

VIII. SONUÇLAR VE TARTIŞMA

A. Genel Başarım

Tablo II nihai başarı sıralamasını verir (Şekil 10 ve 11). İnce ayarlı DistilBERT, 0,8113 F1-makro ile tüm modelleri açık farkla geçerek en iyi sonucu vermiştir; test başarımı doğrulama başarımına (0,8179) çok yakın olduğundan aşırı öğrenme gözlenmemiştir. Klasik modeller arasında ise, sızıntısız biçimde doğrulama olasılıkları üzerinde eğitilen istifleme (stacking) topluluğu 0,7577 ile en iyisidir. Hem DistilBERT hem de güçlü düzenleştirilmiş TF-IDF modelleri, sıfırdan eğitilen dizi tabanlı derin modelleri (LSTM/BiLSTM, $\approx 0,69$) belirgin biçimde geçmektedir. İki gözlem öne çıkar: (i) kısa ve özlü ürün yorumlarında iyi tasarlanmış TF-IDF temsilleri, sınırlı veriyle sıfırdan eğitilen dizi modellerine kıyasla rekabetçi, hatta üstün kalır; (ii) buna karşılık, büyük yığınlarda önceden eğitilip göreve ince ayarlanan bir Transformer (DistilBERT),


aktarım öğrenmesi sayesinde bu tavanı kırarak klasik en iyiye göre +5,4 F1 puanı, önceki temel modele (0,7512) göre ise +6,0 F1 puanı kazanç sağlar.

Tablo II
TEST KÜMESİ NİHAİ BAŞARIMI (F1-MAKRO'YA GÖRE SIRALI)

Model	Doğr.	Kesin.	Duyar.	F1-Mak.
DistilBERT (fine-tuned)	0,8108	0,8119	0,8108	0,8113
Stacking (Blend)	0,7576	0,7578	0,7576	0,7577
Ensemble (Ağırlıklı)	0,7527	0,7527	0,7527	0,7527
SVM	0,7488	0,7473	0,7488	0,7480
Logistic Regression	0,7464	0,7470	0,7464	0,7467
LightGBM	0,7415	0,7429	0,7415	0,7421
ComplementNB	0,7170	0,7126	0,7170	0,7120
BiLSTM	0,6918	0,7028	0,6918	0,6947
LSTM	0,6882	0,6898	0,6882	0,6888

Test kümesi metrikleri				
Değerler 06 numaralı değerlendirme notebook'undaki test sonuçlarından alınmıştır (F1-Macro'ya göre sıralı).				
Model	Accuracy	Precision	Recall	F1-Macro
DistilBERT (fine-tuned)	0.8108	0.8119	0.8108	0.8113
Stacking (Blend)	0.7576	0.7578	0.7576	0.7577
Ensemble (Weighted)	0.7527	0.7527	0.7527	0.7527
SVM	0.7488	0.7473	0.7488	0.7480
Logistic Regression	0.7464	0.7470	0.7464	0.7467
LightGBM	0.7415	0.7429	0.7415	0.7421
ComplementNB	0.7170	0.7126	0.7170	0.7120
BiLSTM	0.6918	0.7028	0.6918	0.6947
LSTM	0.6882	0.6898	0.6882	0.6888

Şekil 10. Web arayüzündeki test kümesi başarıım tablosu; ince ayarlı DistilBERT en üstte (0,8113).



Şekil 11. Test kümesinde modellerin F1-makro ve doğruluk karşılaştırması: ince ayarlı DistilBERT (0,811) en yüksek; istifleme topluluğu (0,758) klasikler içinde önde; sıfırdan eğitilen LSTM/BiLSTM geride kalır.


B. Sözlük Tabanlı Taban Çizgileri ile Karşılaştırma

Denetimli modellerin kattığı değeri ölçmek için, eğitim gerektirmeyen iki sözlük tabanlı yöntem, VADER ve TextBlob, aynı test kümesinde taban çizgisi olarak çalıştırılmıştır (Şekil 13). Her iki yöntem de yalnızca 0,39 ile 0,41 F1-makro düzeyinde kalmış; bu, rastgele tahminin (0,333) ancak bir miktar üzerindedir. Buna karşılık en basit denetimli model bile 0,70'i aşar. Aradaki yaklaşık +0,34 puanlık uçurum, üç sınıflı



Şekil 12. Tüm modeller için normalize karışıklık matrisleri (test). Nötr sınıfı tüm modellerde en çok karıştırılan sınıftır; DistilBERT nötr ayırımında belirgin biçimde daha başarılıdır.

ve nötr içeren bu problemde sabit kutupluluk sözlüklerinin yetersiz kaldığını, göreve özgü denetimli öğrenmenin zorunlu olduğunu nicely olarak doğrular.




Şekil 13. Sözlük tabanlı (VADER, TextBlob) yöntemler ile denetimli ML modellerinin F1-makro karşılaştırması. Sözlük yöntemleri 0,41'i aşamazken ML modelleri 0,70'in üzerindedir.

C. Çapraz Doğrulama ile Kararlılık

Tek bir eğitim/test bölümünün şans eseri iyimser olmadığını doğrulamak için klasik modeller dengeli eğitim kümesinde 5 katlı çapraz doğrulamadan geçirilmiştir (Şekil 14). Katlar arası F1-makro standart sapması tüm modellerde 0,01'in altındadır (LR ort. 0,734; LightGBM 0,719; SVM 0,716; ComplementNB 0,710). Bu düşük varyans, raporlanan tek bölüm skorlarının kararlı ve tekrarlanabilir olduğunu gösterir. Hesaplama maliyeti nedeniyle dizi ve Transformer modelleri bu deneye dahil edilmemiştir.


D. Ayırım Gücü: ROC ve PR Eğrileri

Eşikten bağımsız bir karşılaştırma için her model ve her sınıf bire karşı hepsi (one-vs-rest) kurgusunda değerlendirilmiştir. ROC eğrileri (Şekil 15) tüm modellerin Pozitif ve Negatif sınıflarda köşeye yakın (yüksek AUC) eğriler ürettiğini, nötr sınıfta ise eğrilerin belirgin biçimde köşegene yaklaştığını gösterir. Sınıf dengesizliğine ROC'tan daha duyarlı olan kesinlik ve duyarlılık (PR) eğrileri (Şekil 16) aynı örüntüyü daha keskin ortaya koyar: nötr sınıfın PR eğrisi diğer ikisinin




Şekil 14. Klasik modellerin 5 katlı çapraz doğrulama F1-makro skorları. Katlar arası sapma 0,01'in altındadır (yatay kesikli çizgi ortalamayı gösterir).

belirgin altında seyrederek. Radar grafiği (Şekil 17) dört ölçütü (doğruluk, kesinlik, duyarlılık, F1) tek bakışta özetler; DistilBERT'in çokgeni tüm eksenlerde en dışta, sıfırdan eğitilen dizi modellerininkine ise en içtedir.




Şekil 15. Sınıf başına ROC eğrileri (tüm modeller). Pozitif/Negatif sınıflarda eğriler köşeye yakındır; nötr sınıfta köşegene yaklaşıp.



Şekil 16. Sınıf başına kesinlik ve duyarlılık (PR) eğrileri. Nötr sınıfın eğrisi diğerlerinin belirgin altındadır.


E. İstatistiksel Anlamlılık ve Nötr Sınıf Analizi

DistilBERT ile en iyi klasik model (istifleme) arasındaki farkın rastlantısal olup olmadığını sınamak için eşli (paired) McNemar testi uygulanmıştır. Test kümesinde yalnızca DistilBERT'in doğru bildiği 1.506 örneğe karşılık yalnızca istiflemenin doğru bildiği 794 örnek vardır; süreklilik düzeltmeli $\chi^2 = 219,8$, $p \approx 10^{-49}$. Bu, DistilBERT'in üstünlüğünün istatistiksel olarak son derece anlamlı (rastlantı olmadığı) olduğunu gösterir. Ayrıca, en çok karıştırılan nötr sınıfı için DistilBERT olasılıklarına yalnızca doğrulama kümesinde sınıf başına çarpan (eşik) ayarı uygulanmıştır; bu, nötr duyarlılığını (recall) test kümesinde 0,734'ten 0,761'e çıkarmış, makro-F1'i ise pratikte değiştirmemiştir (model olasılıkları zaten iyi dengelenmiştir). Eşik ayarı, nötr sınıfın zorluğunu nicilemek amacıyla raporlanmış; varsayılan modelde kullanılmamıştır.



Şekil 17. Dört ölçütün radar görünümü. DistilBERT tüm eksenlerde en dış çokgeni oluşturur; LSTM/BiLSTM en içte kalır.

Sınıf bazlı kesinlik/duyarlılık/F1 değerleri (Şekil 18, Lojistik Regresyon örneği) nötr sınıfın sayısal dezavantajını netleştirir: Pozitif (0,80) ve Negatif (0,72) sınıflara karşılık nötr F1 yalnızca 0,64'tür. Bu $\approx 0,08$ ile 0,16 puanlık fark, tüm modellerde gözlenen genel örüntünün tipik bir örneğidir.




Şekil 18. Sınıf bazlı kesinlik/duyarlılık/F1 (Lojistik Regresyon). Nötr sınıf, F1 açısından en zayıf sınıftır (0,64).

Problemin doğasındaki zorluğu görselleştirmek için TF-IDF temsili 50 boyuta (TruncatedSVD) indirgenip test örnekleri t-SNE ile iki boyuta yansıtılmıştır (Şekil 19). Pozitif ve Negatif örnekler kısmen ayrı bölgeler oluştururken nötr örnekler bu iki kümenin arasına ve içine geniş biçimde dağılır; net bir karar sınırı yoktur. Bu görsel, nötr sınıfın neden tüm modellerde en yüksek hata oranına sahip olduğunu (Şekil 12) ve genel başarımın asıl tavanını bu sınıfın belirlediğini sezgisel olarak açıklar.

F. Başlık (Summary) Ablation'ı

Tablo III ve Şekil 20, başlık bütünleştirmenin etkisini gösterir. Başlık eklemek F1-makro skorunu model başına +0,024




Şekil 19. Test örneklerinin t-SNE izdüşümü (TF-IDF + SVD-50). Nötr örnekler (gri) pozitif ve negatif kümelerin arasına dağılır; sınıflar net ayrılmaz.

ile +0,029 arasında artırmıştır; topluluk için kazanç +0,025'tir. Düşük maliyetli (yalnızca öznitelik metnini değiştiren) ama tüm modellerde tutarlı bu iyileşme, başlık alanının taşıdığı duygu sinyalinin değerini doğrular.

Tablo III
BAŞLIK (SUMMARY) ABLATION'I (F1-MAKRO)

Model	Yalnız Metin	Metin+Başlık	Δ
Logistic Regression	0,7203	0,7443	+0,0240
SVM	0,7171	0,7407	+0,0235
LightGBM	0,7157	0,7451	+0,0293
Ensemble	0,7258	0,7512	+0,0254



Şekil 20. Başlık alanının katkısı: her modelde gövde+başlık (yeşil), yalnız gövdeyi (gri) geçer.

G. Topluluk Analizi

İstifleme (stacking) topluluğu, en iyi tekil klasik modeli (SVM, 0,7480) geçerek klasik modeller arasında en yüksek skoru (0,7577) elde etmiştir; ağırlıklı oylamadan (0,7527) da üstündür. Meta modelin doğrulama olasılıklarıyla eğitilmesi (taban modellerin eğitim olasılıklarıyla değil) bu kazancın

sızıntısız ve gerçek olmasını güvence altına alır. Genel sıralamada ise DistilBERT (0,8113) bu klasik tavanı da açık farkla aşmıştır. Şekil 22, “Awful, do not buy” başlıklı olumsuz bir yorumun yüksek güvenle Negatif sınıflandırıldığı örnek bir çıkarımı; Şekil 24 ise tüm modellerin aynı metin için aynı kararı verdiğini gösterir.

Yorum metni

İngilizce bir ürün yorumu girin. Model metni Negatif, Nötr veya Pozitif olarak sınıflandırır ve her sınıf için olasılık üretir.

Başlık (summary) — opsiyonel

Awful, do not buy

Modeller yorum başlığını da kullanır; başlık çoğu zaman duygu-yoğun olduğu için doğruluğu artırır.

This product is terrible, stale and a complete waste of money.

Model

Ensemble (Weighted) (Topluluk)

Analiz et

Hızlı dene: olumlu nötr olumsuz


Şekil 21. Tekli tahmin giriş kartı: opsiyonel başlık (summary) alanı ve model seçimi.

H. Sözlük Dışı (OOV) Kelimeler


Geliştirme sırasında gözlemlenen ilginç bir durum, bazı bariz olumsuz kelimelerin (ör. “shit”) tek başına girildiğinde TF-IDF tarafında karşılık bulamamasıdır. İnceleme, bu kelimenin veri kümesinde yalnızca 9 dokümanda geçtiğini ve max_features=50000 frekans tavanının altında kaldığı için sözlüğe alınmadığını göstermiştir. Bu bir kusur değil, bir gıda yorumu kümesinin doğal sonucudur: kullanıcılar küfür yerine “awful”, “terrible”, “disgusting” ifadelerini tercih eder. Buna rağmen sistemin doğru (Negatif) tahmin üretmesi (Şekil 25), TF-IDF dışındaki sayısal duygu özniteliklerinin (TextBlob polaritesi) modele dayanıklılık kazandırdığını gösterir. Canlı açıklama bu kelimeyi “bilinmiyor” olarak işaretleyerek şeffaflık sağlar.

I. Küresel Öznitelik Önemi

LIME'in örnek bazlı (yerel) açıklamasını tamamlamak üzere, klasik modellerin küresel (model genelinde) en etkili terimleri de incelenmiştir (Şekil 26). Lojistik Regresyon ve ComplementNB'nin sınıf başına en yüksek katsayılı kelimeleri ile LightGBM'in kazanç tabanlı (gain) en önemli öznitelikleri, Bölüm III'teki sınıf ayırt edici sözcüklerle (“not”, “bad”, “disappointed” / “great”, “best”, “love”) büyük ölçüde örtüşür.




Şekil 22. Sonuç kartı: sınıf olasılıkları, metin istatistikleri ve kelime düzeyinde canlı açıklama.



Şekil 23. Canlı LIME vurgusu: “terrible” ve “awful” en güçlü Negatif katkıyı sağlar.


Tüm modeller bu metin için ne diyor?			
Model	Tür	Tahmin	Güven
DistilBERT (fine-tuned)	Transformer	Negatif	%99.37
Stacking (Blend)	Topluluk	Negatif	%95.62
Ensemble (Weighted)	Topluluk	Negatif	%99.59
Logistic Regression	Klasik	Negatif	%99.97
SVM	Klasik	Negatif	%99.4
LightGBM	Klasik	Negatif	%99.41
ComplementNB	Klasik	Negatif	%97.87
LSTM	Derin	Negatif	%99.62
BILSTM	Derin	Negatif	%99.76

Şekil 24. Aynı girdi için tüm modellerin kararı; DistilBERT ve topluluklar dahil dokuz model.



Şekil 25. Sözlük dışı (OOV) örnek: yalnızca “shit” girildiğinde kelime sözlükte olmamasına rağmen sayısal duygu öznitelikleri sayesinde Negatif tahmin edilir.

Bu tutarlılık, modellerin sezgisel ve doğru sözcüksel ipuçlarını öğrendiğini, başarımın yapay bir ezberden değil anlamlı örüntülerden geldiğini, doğrular.




Şekil 26. Klasik modellerin küresel öznitelik önemi (sınıf başına en etkili terimler). Öğrenilen kelimeler keşifsel analizdeki ayırt edici sözcüklerle örtüşür.

J. Klasik vs. Derin Modeller


Derin modellerin geride kalması iki nedene bağlanabilir: (i) hesaplama bütçesi nedeniyle yalnızca 45.000 örnekle eğitilmeleri; (ii) kısa metinlerde n-gram TF-IDF’in zaten güçlü ayırt edicilik sunması. Sıfırdan öğrenilen 64 boyutlu gömüler, sınırlı veriyle zengin anlamsal temsiller oluşturmakta yetersiz kalmaktadır.

Derin modellerin eğitim eğrileri (Şekil 27) bu yetersizliğin nedenini doğrudan gösterir: hem LSTM hem BiLSTM’de eğitim kaybı düzenli biçimde düşerken doğrulama kaybı birinci dönemden sonra artmaya başlar, klasik bir aşırı öğrenme imzası. Erken durdurma en iyi dönemi saklasa da, sınırlı veriyle sıfırdan öğrenilen gömüler doğrulama başarımını $\approx 0,69$ ’da sabitler.



Şekil 27. LSTM ve BiLSTM eğitim/doğrulama kayıp ve doğruluk eğrileri. Doğrulama kaybı birinci dönemden sonra yükselir (aşırı öğrenme).

Başarım tek boyut değildir; Şekil 28 eğitim süresi (log ölçek) ile test F1’ini birlikte verir. Klasik modeller saniyeler mertebesinde eğitilip 0,74 ile 0,75 bandına ulaşırken, DistilBERT $\approx 8,5$ saatlik CPU eğitimiyle 0,81’e çıkar, yani dört kat fazla zaman/hesaplama, ≈ 5 ile 6 puan F1 kazanç karşılığındadır. Bu maliyet/başarım dengesi, hangi modelin hangi koşulda tercih edilmesi gerektiğine dair pratik bir karar çerçevesi sunar.




Şekil 28. Eğitim süresi (log ölçek) ile test F1-makro. Klasik modeller hızlı ve rekabetçi; DistilBERT en yüksek başarıyı yüksek hesaplama maliyetiyle sağlar.


K. Varlık (Aspect) Bazlı Duygu Analizi

Yorum düzeyindeki tek etiketli sınıflandırmayı tamamlamak üzere, gıda yorumlarında sık geçen beş ürün varlığı (aspect),

Tat/Lezzet, Kalite, Fiyat/Değer, Ambalaj ve Doku/Kıvam için cümle düzeyinde varlık bazlı bir analiz yapılmıştır. İlgili anahtar sözcükleri içeren cümleler ayıklanıp en iyi model ile sınıflandırılmıştır. Şekil 29 her varlık için duygu dağılımını, Şekil 30 ise varlık başına ortalama duygu skorunu (0=Negatif, 2=Pozitif) verir. Tat/Lezzet hem en çok bahsedilen hem de ortalaması pozitif bölgeye geçen (1,04) tek varlıktır; buna karşılık Ambalaj (0,93) ve Kalite (0,96) en düşük ortalamalara sahiptir. Başka bir deyişle kullanıcılar ürünün tadını çoğunlukla beğenirken asıl şikayetleri paketlenme ve genel kalite üzerinedir. Bu kısırlım, yorum düzeyi tek bir etiketin gizlediği eyleme dönük geri bildirimi açığa çıkarır ve sistemin pazar analizi değerini somutlaştırır.



Şekil 29. Beş ürün varlığı için duygu dağılımı. Tat/Lezzet en çok bahsedilen varlıktır; Ambalaj ve Kalite görece daha olumsuzdur.



Şekil 30. Varlık başına ortalama duygu skoru (kesikli çizgi nötr=1,0 eşliğidir). Yalnızca Tat/Lezzet eşğin üzerindedir.

IX. WEB ARAYÜZÜ

Tüm bileşenler Flask tabanlı etkileşimli bir web arayüzünde toplanmıştır. Arayüz; tekli tahmin (opsiyonel başlık alanı, model seçimi, olasılık grafiği ve canlı LIME açıklaması, Şekil 21), toplu analiz, model karşılaştırma (Şekil 10 ve 11) ve keşifsel analiz sayfalarını sunar. Tekli tahmin ekranında, seçilen modelin kararının yanı sıra tüm modellerin aynı metin için verdiği kararlar da gösterilerek karşılaştırmalı bir bakış sağlanır (Şekil 24). Giriş ekranı Şekil 21, sonuç kartı Şekil 22, başarımlar tablosu ise Şekil 10’de gösterilmiştir.

X. SINIRLILIKLAR VE GELECEK ÇALIŞMALAR

Sistem yalnızca İngilizce yorumlar için tasarlanmıştır; nötr sınıf, doğası gereği en çok karıştırılan sınıftır ve genel başarımı sınırlayan başlıca etmendir. Canlı açıklama, basitlik için Lojistik Regresyon katsayılarına dayanır; seçilen model DistilBERT olsa dahi kelime önemi LR üzerinden gösterilir; bu, BERT için doğrudan bir açıklama olmadığından bir sınırlılıktır. DistilBERT yalnızca CPU ve dengeli 62.486 örnekle, iki dönem eğitilmiştir; daha fazla veri/dönem ve GPU ile başarımın bir miktar daha artması olasıdır. Gelecek çalışmalarda: (i) daha güçlü veya duyguya özel önceden eğitilmiş Transformer'lar (RoBERTa, BERT-base) ile başarımın daha da yükseltilmesi; (ii) DistilBERT'in de katıldığı klasik+Transformer toplulukları; (iii) DistilBERT'e özgü dikkat (attention)/SHAP tabanlı açıklamalar; (iv) çok dilli (Türkçe dahil) desteğin eklenmesi hedeflenmektedir.

XI. SONUÇ

Bu çalışma, Amazon ürün yorumları için üç sınıflı, uçtan uca ve açıklanabilir bir duygu analizi sistemi sunmuştur. Önerilen geliştirmeler, başlık bütünleştirme, istifleme (stacking) topluluğu, canlı LIME açıklaması ve önceden eğitilmiş bir Transformer'ın (DistilBERT) ince ayarlanması, birlikte hem doğruluğu hem de yorumlanabilirliği belirgin biçimde artırmıştır. Sızıntısı giderilmiş istifleme topluluğu klasik modeller arasında 0,7577 F1-makro ile en iyi olurken, ince ayarlı DistilBERT 0,8113 F1-makro ile tüm modelleri geçerek genel en iyi sonucu vermiş; önceki temel modele göre +6 F1 puanı kazanç sağlanmıştır. Ayrıca öznitelik çıkarımındaki bir veri sızıntısı giderilip tüm model seçimleri yalnızca doğrulama kümesinde yapılarak değerlendirilmenin güvenilirliği güçlendirilmiştir. Sonuçlar iki tamamlayıcı bulguyu ortaya koyar: iyi tasarlanmış klasik öznitelik mühendisliği ve hafif topluluk yöntemleri, sınırlı veri/hesaplama koşullarında sıfırdan eğitilen derin dizi modellerine kıyasla güçlü, hızlı ve yorumlanabilir bir taban sunar; buna karşılık, aktarım öğrenmesiyle gelen önceden eğitilmiş bir Transformer'ın ince ayarı, bu tabanı aşan en yüksek başarımı sağlar.

KAYNAKLAR

- [1] J. McAuley and J. Leskovec, "From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews," in *Proc. Int. Conf. World Wide Web (WWW)*, 2013, pp. 897–908.
- [2] B. Pang and L. Lee, "Opinion mining and sentiment analysis," *Found. Trends Inf. Retr.*, vol. 2, no. 1–2, pp. 1–135, 2008.
- [3] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [4] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017, pp. 3146–3154.
- [5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [6] M. T. Ribeiro, S. Singh, and C. Guestrin, "Why should I trust you?: Explaining the predictions of any classifier," in *Proc. ACM SIGKDD*, 2016, pp. 1135–1144.
- [7] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Proc. ECML*, 1998, pp. 137–142.
- [8] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter," in *NeurIPS EMC² Workshop*, 2019.

- [9] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.
- [10] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, and J. Dean, "Distributed representations of words and phrases and their compositionality," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2013, pp. 3111–3119.
- [11] Y. Kim, "Convolutional neural networks for sentence classification," in *Proc. Conf. Empir. Methods Nat. Lang. Process. (EMNLP)*, 2014, pp. 1746–1751.
- [12] A. Vaswani *et al.*, "Attention is all you need," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017, pp. 5998–6008.
- [13] M. Hu and B. Liu, "Mining and summarizing customer reviews," in *Proc. ACM SIGKDD*, 2004, pp. 168–177.
- [14] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017, pp. 4765–4774.
- [15] R. Socher *et al.*, "Recursive deep models for semantic compositionality over a sentiment treebank," in *Proc. Conf. Empir. Methods Nat. Lang. Process. (EMNLP)*, 2013, pp. 1631–1642.